

QUEST na cvičení

- Dataset pre tento projekt je **Netflix 10+ Year Stock Data** stiahnutý z kaggle.com
- Názov datasetu je NFLX

IMPORTY

```
In [1]: # ==IMPORTY ==
import pandas as pd
import numpy as np

import matplotlib.pyplot as plt
import seaborn as sns
# Zobrazovanie grafov
%matplotlib inline

df = pd.read_csv("NFLX.csv")
df.head()
```

```
Out [1]:
```

	Date	Open	High	Low	Close	Adj Close	Volume
0	2002-05-23	1.156429	1.242857	1.145714	1.196429	1.196429	104790000
1	2002-05-24	1.214286	1.225000	1.197143	1.210000	1.210000	1104800
2	2002-05-28	1.213571	1.232143	1.157143	1.157143	1.157143	6609400
3	2002-05-29	1.164286	1.164286	1.085714	1.103571	1.103571	6757800
4	2002-05-30	1.107857	1.107857	1.071429	1.071429	1.071429	10154200

4.1 EDA and data preprocessing

4.1(A) EDA a data preprocessing pre Vami vybrané charakteristiky z datasetu

Základné informácie o datasete:

```
In [8]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4581 entries, 0 to 4580
Data columns (total 7 columns):
 #   Column      Non-Null Count  Dtype
---  --
 0   Date        4581 non-null   datetime64[ns]
 1   Open        4581 non-null   float64
 2   High        4581 non-null   float64
 3   Low         4581 non-null   float64
 4   Close       4581 non-null   float64
 5   Adj Close   4581 non-null   float64
 6   Volume      4581 non-null   int64
dtypes: datetime64[ns](1), float64(5), int64(1)
memory usage: 250.7 KB

Všetky data sú v type int alebo float.

Zistili sme, že dátum je v nesprávnom type preto ho pretypujeme na datetime a zoradíme dataset podľa dátumu
```

```
In [9]: # Pretypovanie dátumu
df["Date"] = pd.to_datetime(df["Date"], errors='coerce')

# Zoradenie podľa dátumu
df = df.sort_values("Date").reset_index(drop=True)
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4581 entries, 0 to 4580
Data columns (total 7 columns):
 #   Column      Non-Null Count  Dtype
---  --
 0   Date        4581 non-null   datetime64[ns]
 1   Open        4581 non-null   float64
 2   High        4581 non-null   float64
 3   Low         4581 non-null   float64
 4   Close       4581 non-null   float64
 5   Adj Close   4581 non-null   float64
 6   Volume      4581 non-null   int64
dtypes: datetime64[ns](1), float64(5), int64(1)
memory usage: 250.7 KB

Ďalej sme sa pozreli na chýbajúce údaje pomocou nasledujúceho kódu:
```

```
In [10]: print("Počet chýbajúcich hodnôt v jednotlivých stĺpcoch:")
df.isna().sum()
```

Počet chýbajúcich hodnôt v jednotlivých stĺpcoch:

```
Out [10]:
```

	Date	Open	High	Low	Close	Adj Close	Volume
count	0	0	0	0	0	0	0
Open	0	0	0	0	0	0	0
High	0	0	0	0	0	0	0
Low	0	0	0	0	0	0	0
Close	0	0	0	0	0	0	0
Adj Close	0	0	0	0	0	0	0
Volume	0	0	0	0	0	0	0
dtype:	int64	int64	int64	int64	int64	int64	int64

Po výpise sme zistili že žiadny stĺpec v datasete nemá chýbajúce údaje, čo je pozitívna informácia

```
In [11]: df.describe()
```

```
Out [11]:
```

	Date	Open	High	Low	Close	Adj Close	Volume
count	4581	4581.000000	4581.000000	4581.000000	4581.000000	4581.000000	4.581000e+03
mean	2011-06-27 20:17:07.897838592	78.031471	79.285690	76.736079	78.072056	78.072056	1.760516e+07
min	2002-05-23 00:00:00	0.377857	0.410714	0.346429	0.372857	0.372857	2.856000e+05
25%	2006-12-07 00:00:00	3.778571	3.857143	3.685714	3.784286	3.784286	6.908900e+06
50%	2011-06-27 00:00:00	15.392858	15.671429	14.970000	15.324286	15.324286	1.155350e+07
75%	2016-01-14 00:00:00	97.830002	99.529999	96.760002	97.889999	97.889999	2.113440e+07
max	2020-08-03 00:00:00	567.979980	575.369995	520.960022	548.729980	548.729980	3.234140e+08
std	NaN	118.372084	120.276839	116.376768	118.435303	118.435303	1.971130e+07

Časové rozhranie je od roku 2012 až po rok 2020, čo znamená časové rozhranie okolo 18 rokov.

Podľa percentuálneho rozdelenia vidno, že dáta sú priemerne rozdelené

Štandardná odchylka je približne 118 čo naznačuje výkuk volatilitu


Dataset neobsahuje záporné hodnoty ani žiadne nelogické hodnoty, čo znamená že dataset je konzistentný

Vývoj cien


```
In [12]: plt.figure(figsize=(14,6))
plt.plot(df["Date"], df["Close"], label="Close price", color="blue")
plt.title("Vývoj ceny akcie Netflix (Close) v čase")
plt.xlabel("Dátum")
plt.ylabel("Cena [USD]")
plt.grid(True)
plt.legend()
plt.show()
```



```
In [13]: plt.figure(figsize=(14,6))
plt.plot(df["Date"], df["Volume"], label="Volume", color="orange")
plt.title("Vývoj objemu obchodovania (Volume) v čase")
plt.xlabel("Dátum")
plt.ylabel("Objem obchodov")
plt.grid(True)
plt.legend()
plt.show()
```



```
In [14]: plt.figure(figsize=(10,5))
plt.hist(df["Close"], bins=40, color="skyblue", edgecolor="black")
plt.title("Histogram uzatváraciej ceny (Close)")
plt.xlabel("Cena [USD]")
plt.ylabel("Počet dní")
plt.grid(True)
plt.show()
```



Netflix mal v histórii viacero splátov

To znamená:

- staré ceny boli spätne prepočítané na extrémne nízke hodnoty (1–5 USD)
- nové ceny pred splátmi boli prepočítané smerom nadol
- historické rozdelenie tak nie je prirodzené, ale technicky upravené

```
In [15]: df["MA7"] = df["Close"].rolling(window=7).mean()
df["MA30"] = df["Close"].rolling(window=30).mean()

plt.figure(figsize=(14,6))
plt.plot(df["Date"], df["Close"], label="Close", alpha=0.5)
plt.plot(df["Date"], df["MA7"], label="MA7 (7-dňový priemer)")
plt.plot(df["Date"], df["MA30"], label="MA30 (30-dňový priemer)")
plt.title("Close + Moving Averages")
plt.legend()
plt.grid(True)
plt.show()
```




MA7 zachytáva krátkodobé výkyvy

MA30 je hladší a zachytáva trend.

Denné výnosy

```
In [16]: df["Return"] = df["Close"].pct_change()


plt.figure(figsize=(10,5))
plt.hist(df["Return"], bins=50, edgecolor="black")
plt.title("Histogram denných výnosov (Return)")
plt.xlabel("Denný výnos")
plt.ylabel("Počet dní")
plt.grid(True)
plt.show()
```



Väčšina denných výnosov je sústredená blízko 0, čo je typické pre akciové trhy. Rozdelenie má dlhé chvosty – občasné extrémne kladné alebo záporné pohyby predstavujú obdobia vysokej volatility (earnings, správy, krízové udalosti). Tento atribút zachytáva dynamiku zmien ceny lepšie než samotné absolútne hodnoty Close.

Korelačná mapa


```
In [17]: features_for_corr = ["Open", "High", "Low", "Close", "Adj Close", "Volume", "MA7", "MA30", "Return"]
plt.figure(figsize=(10,6))
sns.heatmap(df[features_for_corr].corr(), annot=True, cmap="coolwarm", linewidths=0.5)
plt.title("Korelačná matica vybraných charakteristík")
plt.show()
```



Medzi cenovými atribútmi (Open, High, Low, Close, Adj Close) vidíme veľmi silnú koreláciu (blízko 1), čo znamená, že nesú podobnú informáciu a sú do veľkej miery redundantné. MA7 a MA30 sú tiež silno korelované s Close, ale zároveň filtrujú krátkodobý šum. Volume má nižšiu koreláciu s cenou, no môže pomôcť zachytiť dni so zvýšenou aktivitou. Return má len slabú koreláciu s úrovňou ceny, čo dáva zmysel – ide o zmenu, nie o samotnú úroveň.

```
In [ ]: df["Volatility"] = df["Return"].rolling(window=7).std()

plt.figure(figsize=(14,6))
plt.plot(df["Date"], df["Volatility"], label="7-day Rolling Volatility", color="purple")
plt.title("7-dňová volatilita výnosov")
plt.xlabel("Dátum")
plt.ylabel("Volatilita")
plt.grid(True)
plt.legend()
plt.show()
```



Volatilita predstavuje mieru kolísania ceny v čase. Vyššie hodnoty volatility znamenajú, že denná zmena ceny bola nestabilná a akcia zaznamenala výraznejšie pohyby. Na grafe vidíme niekoľko výrazných špičiek (napr. okolo rokov 2004, 2008, 2013 a 2015), ktoré typicky súvisia s earnings správami, trhovými šokmi alebo významnými udalosťami v spoločnosti Netflix.

4.1(B) Zdôvodnenie výberu ML/DL metód vzhľadom na vybraný dataset pre 4.2

Keďže v tejto úlohe pracujeme s datasetom Netflix 10+ Year Stock Data, ktorý obsahuje dlhodobý časový rad denných cien akcií, je teda vhodné na základe predchojej analýzy použiť také metódy ktoré dokážu pracovať s časovými radmi alebo zachytiť nelineárne spracovanie dát

Voľba LM metód

Lineár regresión Lineárna regresia slúži ako základný model. Je rýchla a poskytuje referenčnú hodnotu, voči ktorej môžeme porovnať výkon zložitejších modelov. Napriek tomu, že ceny akcií majú nelineárny vstupný charakteristikami, ktoré môžu byť navzájom korelované (napr. Open, High, Low, Close).

Random Forest Regressor Random Forest je vhodný pre finančné dáta, pretože dokáže zachytávať nelineárne vzťahy, je robustný voči outlierom a nevyžaduje normalizáciu. Takisto dobre pracuje s viacermi vstupnými charakteristikami, ktoré môžu byť navzájom korelované (napr. Open, High, Low, Close).

Gradient Boosting / XGBoost Boosting modely patria medzi najúčinnejšie metódy pre tieto dáta. vedľa sa naučiť aj zložitejšie vzory, ktoré jednoduchšie modely nemusia vidieť. Veľmi dobre pracujú s trendom aj s volatilitou. Výhodou sú dobré výsledky aj pri menších datasetoch čo sa nám akurát hodi

4.2 Modeling evaluation

4.2(A) Modeluje Vami tie vybrané charakteristiky pomocou vhodných ML/DL metód. Výsledok modelovania je najlepší model.

4.2(B) Zhodnotíte Váš prístup a získaný výsledok