

QUEST na cvičení

- Dataset pre tento projekt je **Netflix 10+ Year Stock Data** stiahnuť z [kaggle.com](#)
- Názov datasetu je **NFLX**

IMPORTY

```
In [1]: # === IMPORTY ===
import pandas as pd
import numpy as np

import matplotlib.pyplot as plt
import seaborn as sns
# Zobrazenie gridfov
%matplotlib inline

df = pd.read_csv("NFLX.csv")
df.head()
```

```
Out [1]:
```

	Date	Open	High	Low	Close	Adj Close	Volume
0	2002-05-23	1.156429	1.242857	1.145714	1.196429	1.196429	104790000
1	2002-05-24	1.214286	1.225000	1.197143	1.210000	1.210000	11104800
2	2002-05-28	1.213571	1.232143	1.157143	1.157143	1.157143	6609400
3	2002-05-29	1.164286	1.164286	1.085714	1.103571	1.103571	6757800
4	2002-05-30	1.107857	1.107857	1.071429	1.071429	1.071429	10154200

4.1 EDA and data preprocessing

4.1(A) EDA a data preprocessing pre Vami vybrané charakteristiky z datasetu

Základné informácie o datasete:

```
In [8]: df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4581 entries, 0 to 4580
Data columns (total 7 columns):
 #   Column      Non-Null Count  Dtype  
---  --
 0   Date        4581 non-null   datetime64[ns]
 1   Open        4581 non-null   float64
 2   High        4581 non-null   float64
 3   Low         4581 non-null   float64
 4   Close       4581 non-null   float64
 5   Adj Close   4581 non-null   float64
 6   Volume      4581 non-null   int64  
dtypes: datetime64[ns](1), float64(5), int64(1)
memory usage: 250.7 KB

Všetky data su v type int alebo float.

Zistili sme,že dátum je v nesprávnom type preto ho pretypujeme na datetime a zoradíme dataset podľa dátumu
```

```
In [9]: # Pretypovanie dátumu
df['Date'] = pd.to_datetime(df['Date'], errors='coerce')

# Zoradenie podľa dátumu
df = df.sort_values("Date").reset_index(drop=True)
df.info()
```





```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4581 entries, 0 to 4580
Data columns (total 7 columns):
 #   Column      Non-Null Count  Dtype  
---  --
 0   Date        4581 non-null   datetime64[ns]
 1   Open        4581 non-null   float64
 2   High        4581 non-null   float64
 3   Low         4581 non-null   float64
 4   Close       4581 non-null   float64
 5   Adj Close   4581 non-null   float64
 6   Volume      4581 non-null   int64  
dtypes: datetime64[ns](1), float64(5), int64(1)
memory usage: 250.7 KB

Ďalej sme sa pozreli na chýbajúce údaje pomocou nasledujúceho kódu:
```

```
In [10]: print("Počet chýbajúcich hodnôt v jednotlivých stĺpcoch:")
df.isna().sum()
```

```
Počet chýbajúcich hodnôt v jednotlivých stĺpcoch:
Out [10]: Date      0
Open      0
High      0
Low       0
Close     0
Adj Close 0
Volume    0
dtype: int64


Po výpise sme zistili že žiadny stĺpec v datasete nemá chýbajúce údaje, čo je pozitívna informácia
```



Netflix mal v histórii viacero splívov

To znamená:

- staré ceny boli spätne prepočítané na extrémne nízke hodnoty (1–5 USD)
- nové ceny pred splítni boli prepočítané smerom nadol
- historické rozdelenie tak nie je prirodzené, ale technicky upravené



MA7 zachytáva krátkodobé výkyvy

MA30 je hladší a zachytáva trend.

4.1(B) Zdôvodnenie výberu ML/DL metód vzhľadom na vybraný dataset pre 4.2

4.2 Modeling evaluation

4.2(A) Modeluje Vami tie vybrané charakteristiky pomocou vhodných ML/DL metód. Výsledok modelovania je najlepší model.

4.2(B) Zhodnotíte Váš prístup a získaný výsledok